

# Aplicació Interactiva per a la Predicció i Seguiment del Rendiment Acadèmic

Joel Tapia Salvador

**Resum**— Projecte amb l'objectiu de crear una aplicació web interactiva que permeti a les famílies visualitzar una predicció o anàlisis del rendiment acadèmic dels seus fills. S'assoleix l'objectiu a partir de dades introduïdes per la família mateixa sobre les activitats, temps d'estudi, rendiment anterior dels seus fills i altra informació, a partir de la qual un model, o diversos, predictiu crea un perfil. A més a més, oferirà funcionalitats interactives i recomanacions per millorar el rendiment, centrat a facilitar el suport per part de les famílies als seus fills.

**Paraules clau**— Aplicacions, Avaluació del rendiment, Educació, Intel·ligència Artificial, Modelatge, Perfils d'usuari i serveis d'alerta, Personalització, Serveis basats en web, Suport a la presa de decisions, Visualització

**Abstract**—Project with the objective of creating an interactive web application to allow families to visualize a prediction or analysis of their kid's academic performance. This is achieved using data introduced by the own family about the activities, time spent studying, past performance of their kid and other information, which one, or several, predictive models will use to create a profile. In addition, it will offer interactive recommendations to improve the performance of the kids, focused on improving the assistance given by the families to their own kids.

**Index Terms**— Applications, Artificial Intelligence, Decision support, Education, Modelling, Performance evaluation, Personalization, User profiles and alert services, Visualization, Web-based services

## 1 INTRODUCCIÓ

AQUEST treball té com a objectiu desenvolupar, en un àmbit purament acadèmic, una aplicació web interactiva amb models d'intel·ligència artificial que puguin predir el rendiment acadèmic dels fills de famílies a través de la informació introduïda a l'aplicatiu.

Un dels principals punts a investigar és quin or quins models performen de forma més remarcable a l'hora de predir els resultats acadèmics i com millorar-los.

Per poder fer l'entrenament necessitem un conjunt de dades extens, unificat i ampli amb possibles dades acadèmiques, d'estudi i oci que poden afectar el rendiment.

L'aplicatiu serà senzill, dut que l'objectiu es recerca acadèmica, no es posarà molta feina en l'aspecte visual de l'aplicatiu ni que pugui ser massivament desplegat com a servei web, sinó, que sigui funcional.

## 2 ESTAT DE L'ART

### 2.1 Model predictiu

L'avaluació i predicció del rendiment acadèmic utilitzant intel·ligència artificial ha sigut objectiu d'estudi en altres recerques. A partir d'aquest podem observar quins mo-

dels han sigut fet servits mes sovint i quins tenen millor resultat per reduir la quantitat de models que entrenar i testejar.

Un dels models utilitzats ha sigut la *Logistic Regression* (LR) tal com es presenta a [1], [2], [3], [4], [6], [7], [8] i [10] amb una *accuracy* oscil·lant d'un 57.9% a un 92,1%.

Un altre model és *Support Vector Machine* (SVM) vist a [1], [3], [5], [6], [9] i [10] amb l'interval de resultats en *accuracy* de 60.0% a 93,9%.

També s'utilitza de forma habitual els *Decision Trees* (DT) amb l'*accuracy* variant de 42.0% fins 95.7% tal com mostren [1], [2], [3], [4], [5], [6], [9] i [10]. Algunes d'aquestes implementacions són DT especials tal com *Bagging Trees* [9] i *Boosting Trees* [9].

A [1], [3], [6], [7], [8] i [9] també es fa servir *Random Forest* amb un *accuracy* que varia del 52.9% al 96.1%.

Un model menys utilitzat és *Naïve Bayesian Algorithm* en [3], [4], [5], [6] i [9] amb una *accuracy* de 50.0% a 76.0%.

També s'implementa molt *Artificial Neural Networks* (ANN) com vist a [2], [3], [4], [5], [6], [8] i [10]. Aquests inclouen models com *Backpropagation Neural Networks* (BPNN) [2], *Radial-Basis Function Neural Networks* (RBFNN) [2], *Recurrent Neural Networks* (RNN) [4], *Long Short Term Memory* (LSTM) [4] i *Multi Layer Perceptrons* (MLP) [4]. Aquests models tenen una *accuracy* de 65.0% a 91.5%.

- E-mail de contacte: Joel.TapiaS@uab.cat
- Treball tutoritzat per: Oriol Cortés Comellas (Àrea de Ciències de la Computació i Intel·ligència Artificial)
- Curs 2024/25

## 2.2 Aplicatiu interactiu

Per a desenvolupar aplicatius webs en Python [11] s'utilitza Django [12], Flask [13] i FastAPI [14].

HTMX [15] en una opció popular per afegir interactivitat sense necessitat d'un *framework* JavaScript [16] complet. Alpine.js [17] és una llibreria JavaScript lleugera sovint feta servir per a petits elements interactius. Tot i que *frameworks* més complets com React [18] es poden integrar amb *backends* Python, normalment es reserven per a aplicacions més complexes.

Pel que fa a l'estil, *Bootstrap* [19] continua sent el *framework* més utilitzat per la seva facilitat d'ús i capacitat de disseny responsiu.

Els desenvolupadors Python sovint fan servir motors de plantilles com Jinja [20] per generar HTML [21] dinàmicament i integrar-se fàcilment amb aquestes eines de *frontend*.

En el *backend* amb Python normalment es fan servir base de dades com PostgreSQL [22] o SQLite [23].

## 3 METODOLOGIA

### 3.1 Metodologia entrenament model

Per entrenar els models aplicarem entrenament amb *K-Folds* com es veu a Fig. 1. En el pas 1 dividirem el conjunt de dades en *K folds*. S'aplicaran *K* iteracions on a cada iteració s'agafarà un subconjunt dels *folds* com a conjunt d'entrenament i els restants com a conjunt de test.

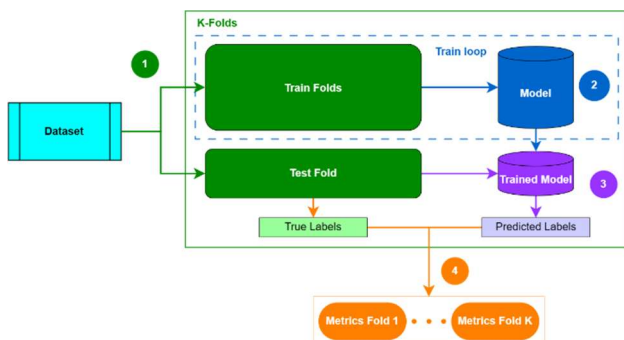


Fig. 1. Diagrama de la metodologia general *K-Fold* per l'entrenament dels models.

Al pas 2, en cada iteració, s'agafarà el conjunt d'entrenament i s'entrenarà el model. En el pas 3, una vegada el model s'hagi entrenat, es faran prediccions sobre el conjunt de test. En el pas 4 es compararan les prediccions amb els *groundtruth*, s'obtingueran mètriques i s'acumularan totes les mètriques obtingudes per cada iteració del *K-Fold*.

En concret el nostre procediment per escollir models i entrar-los serà esplotat a la següent secció.

### 3.2. Metodologia de decisió de models

Com es veu a l'estat de l'art hi ha moltes possibles arquitectures per obtenir el nostre objectiu, totes aquestes amb variats resultats. Per poder decidir quina utilitzar per a l'aplicatiu és necessari provar-les amb les dades que es faran servir i veure el seu rendiment.

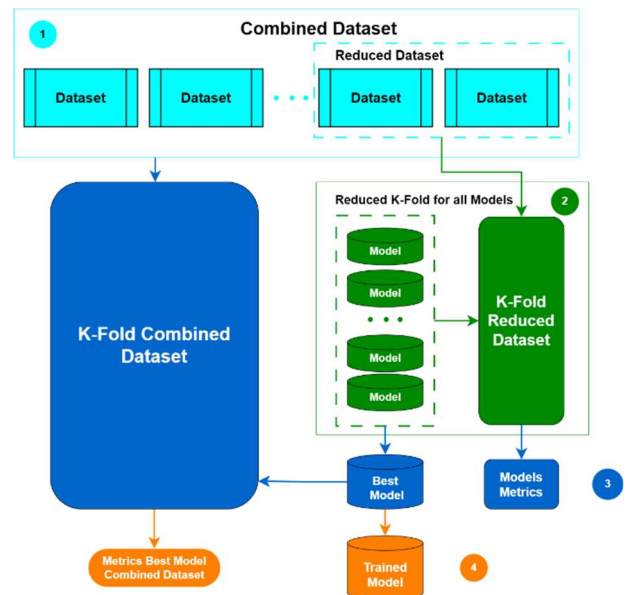


Fig. 2. Diagrama de la metodologia a seguir per decidir el millor model per l'aplicatiu.

Per fer això implementarem la metodologia de la Fig. 2. Al pas 1 combinarem diversos conjunts de dades en un sol. Al pas 2 agafarem un petit subconjunt del nou conjunt de dades i aplicarem la metodologia d'entrenament de model de la Fig. 1 sobre aquest subconjunt per cada model que utilitzarem. Al pas 3 tindrem les mètriques de tots els *K-Folds* per a tots els models i escollirem el model amb millor rendiment en les prediccions. Al pas 4, amb aquest millor model, l'entrenarem fent servir la metodologia *K-Folds* amb totes les dades del conjunt complet, obtenint les mètriques finals i el model entrenat que utilitzarem a l'aplicatiu.

Els diferents models que es treballarà seran LR, SVM, DT, RF i ANN.

### 3.5 Metodologia recomanador de millores

Per ajudar als estudiants, desenvoluparem un recomanador de quins aspectes a millorar per augmentar el rendiment acadèmic.

Aquest recomanador, alterar els valors actuals del estudiant, fins que hi trobi l'alteració d'un d'ells que, segons el model classificador, millori el rendiment i suggerirà al estudiant a provar a fer el canvi i veure si el millora.

A partir d'aquí es podria implementar un sistema de validació que a futur, preguntant al estudiant si ha aplicat el canvi suggerint, com s'han vist modificat el rendiment i actualitzar el model amb aquesta informació.

### 3.4 Metodologia desenvolupament aplicatiu

Per desenvolupar l'aplicatiu web interactiu s'utilitzarà la metodologia *Test-driven Development*. Aquesta metodologia comença dissenyant una sèrie de tests que el programari ha de superar pel seu correcte funcionament i a continuació es crea el programari satisfent els tests.

Primer es treballarà en les connexions del *backend* amb el model i base de dades necessàries. A continuació la estructura del *backend* web. I, finalment, el *frontend*.

## 4 PLANIFICACIÓ

Per dur a terme el projecte de forma correcta i a tems s'ha designat una planificació a seguir fins al final del període. S'ha fet un gràfic de Gant amb aquesta, es pot veure al annex. S'ha planificat pel temps que es trigarà en preparar tots els conjunts de dades, fer les proves inicials de decisió de model. Fer l'entrenament del model final i desenvolupar cada fase de l'aplicatiu. També s'ha planificat les entregues durant el termini, incloent mantenint el dossier i la preparació de la presentació.

## 5 DATA

Per poder entrenar els models necessitem dades sobre diferents estudiants. Trobem base de dades ([24], [25] i [26]) no molt grans però que a més tenen alguns paràmetres en comú, altres no i tots expressats de forma diferent. Per això ajuntarem tots les bases de dades en una sola.

Al unificar les bases de dades, acabem amb variables que son:

1. Innates e invariants del estudiant, com: edat, educació dels pares, nivell actual de l'educació, etc.
2. Dificils de modificar pel estudiant, com: lloc de residència, accés a internet, etc.
3. Alterables pel estudiant, com: nombre d'hores estudiades, nombre d'absències, prendre notes a classe, etc.

Aquesta distinció serà rellevant pel recomandar.

Per poder unificar les base de dades primer em de transformar les dades comuns de tots les bases de dades en un mateix format i rang de dades. Com que la base de dades te dades categòriques i continues, em de fer dos passos.

Primer unifiquem totes les variables categòriques amb la mateix codificació, fent un mapeig per cada base de dades de forma que al final quedi una codificació consistent.

Segon unifiquem es valors continues, escalant-los tots de forma que tinguin el mateix rang de 0 a 1.

El següent pas es afegir a les bases de dades les variables de les altres que no tenen per fer això escollim un valor, "-1", que indicarà que no hi ha informació d'una variable en una observació donada. Això també ens permetrà entrenar models que no necessitin totes les dades ja que a l'aplicatiu real es d'esperar que no sempre es sàpiga totes les dades o que els usuaris les volen dir totes.

En el cas de les notes, quines son el nostre objectiu, hi ha alguns sistemes i bases de dades que les categoritzen (Excelent, Notable, A+, B, etc.) i d'altres que son numèriques a diferents escales. A la mateixa hora, alguns dels nostres models son classificadors, d'altres regressius i la xarxa neuronal se'l por fer entrenar ambdues a l'hora amb múltiple *losses* i sortides. Per això, com que inherent hi ha un ordre encara que siguin classes, s'han codificat les classes en 5 numèrics enters depenent del país d'origen.

Totes aquestes operacions i transformacions de la base de dades les drem a terme utilitzant el mòdul *Pandas* [27] de *Python*.

## 6 ENTRENAMENT MODELS

Per entrenar els models i decidir quin és el millor utilitzem un subet aleatori de la base de dades que hem creat y apliquem un K-Fold amb 5 grups on a cada Fold entrenem tots els tipus de models, calculem les mètriques i comparem els resultats. Utilitzem els mètodes de K-Fold de *Sklearn* [28] de *Python*.

Els DT, RF i LR que utilitzarem també son les implementacions del mòdul *Sklearn* i per a les ANN utilitzarem el mòdul *Torch* [29] de *Python*.

Com comentat abans, les notes son numèriques dividides en classes i per tant a partir d'ara tots les prediccions de les regressions seran aproximades als enters y els valors *clipped* dins del rang 0-4. Utilitzarem per comparar els resultats mètriques de classificació i mètriques de regressió.

Degut a problemes i complicacions amb el model de ANN, calcular tots el tipus de mètrics i efectes externs, el ANN i SVC han estar enrederits, de moment compararem el resultat dels models DT, RF i LR.

Com es pot veure RF Classifier té una *accuracy* major especialment comparat amb LR i RF Regressor, en canvi LR y RF Regressor té una millor R2 i MSE, quan s'equivoquen ho fan a menys distancia ja que no son classes, però RF Classifier està a prop, encara que té una MSE bastant més gran. En canvi els DT s'aproximen a RF Classifier en *accuracy* però té errors molt grans i llunyans quan s'equivoca.

També podem observat que tots els models tenen desviacions estàndards similars, relativament petites, encara que hi ha diferencia. Son bastant variades a les diferents mètriques, però podem observar que òbviament, el LR te molta més variació a les mètriques de classificacions que a les de regressions i RF Classifier l'oposat.

TAULA 1  
MITJANA I DESVIACIÓ ESTÀNDARD DE LES MÈTRQUES DE CLASSIFICACIONS SOBRE FOLDS

Model	Accuracy	F1 Score
DT Classifier	79.4% ± 0.6%	0.381 ± 0.063
DT Regressor	80.1% ± 0.8%	0.332 ± 0.073
RF Classifier	82.4% ± 1.0%	0.474 ± 0.039
RF Regressor	71.6% ± 0.6%	0.234 ± 0.013
LR	70.4% ± 1.5%	0.216 ± 0.025

TAULA 2  
MITJANA I DESVIACIÓ ESTÀNDARD DE LES MÈTRQUES DE REGRESSIONS SOBRE FOLDS

Model	MAE	MSE	RMSE	R2
DT Classifier	1.408 ± 0.047	4.409 ± 0.184	2.099 ± 0.044	-0.492 ± 0.063
DT Regressor	1.32 ± 0.033	4.047 ± 0.105	2.012 ± 0.026	-0.37 ± 0.033
RF Classifier	1.221 ± 0.103	3.879 ± 0.408	1.967 ± 0.104	-0.313 ± 0.136
RF Regressor	1.199 ± 0.037	2.46 ± 0.166	1.568 ± 0.053	0.167 ± 0.056
LR	1.223 ± 0.068	2.381 ± 0.166	1.542 ± 0.054	0.194 ± 0.055

Encara així, la nostra prioritat es la major *accuracy* possible, es millor no equivocar-se en les notes previstes, diferencia entre preveure nota màxima i l'anterior implica molta diferencia. La major *accuracy* es donada pel RF Classifier, amb una desviació no significativament gran.

Per la segona fase s'ha decidit utilitzar RF Classifier amb els *K-Folds* de totes les dades.

TAULA 3

MITJANA I DESVIACIÓ ESTÀNDARD DE LES MÈTRQUES DE CLASSIFICACIONS DE RF CLASSIFIER SOBRE FOLDS

Model	Accuracy	F1 Score
RF Classifier	83.5% $\pm$ 0.6%	0.475 $\pm$ 0.013

TAULA 4

MITJANA I DESVIACIÓ ESTÀNDARD DE LES MÈTRQUES DE REGRESSIONS DE RF CLASSIFIER SOBRE FOLDS

Model	MAE	MSE	RMSE	R2
RF Classifier	1.121 $\pm$ 0.055	3.535 $\pm$ 0.221	1.879 $\pm$ 0.06	-0.197 $\pm$ 0.075

Com podem veure als resultats de la mitjana de les mètriques del model RF sobre 5 *K-Folds* del data set complet, té resultats molt similars als anteriors, inclús millorant-los tots, disminuint el marge d'error. Encara això el resultats no son molt positius, ja que falla bastant.

## 7. RECOMANADOR

Per poder fer un recomanador de com millorar el rendiment acadèmic necessitem utilitzar aquells paràmetres que son possibles de canviar pel estudiant. Això redueix bastant el espai possible del nostre data set, de 51 paràmetres a 15.

El recomanador agafa per cada paràmetre el tots els possibles valors i mira com varia la predicció del classificador amb cada possibilitat. Al final guardar el valor de quin paràmetre dona el millor rendiment.

Hi ha situacions especials, hi ha estudiants a la base de dades dels quals no tenim valors dels paràmetres modificables, i una altre gran part que ja posseeixen el màxim rendiment, i dels restants, amb els pocs paràmetres modificables, i, lo poc específic que poden ser, el recomanador pel no ha donat molt benefici.

TAULA 5

RESULTATS DEL RECOMANADOR DEL MODEL SOBRE LA BASE DE DADES

Resultat Recomanador	Percentage
Tenen ja el millor rendiment	45.9%
No tenen parametres que es poden modificar	44.6%
Millora	1.0%
Es manté	8.5%
Empitjora	0.0%

## 8. CONCLUSIÓ

Degut a les complicacions no s'han pogut finalitzar de comparar tots els models, però per les previsions amb els altres models, la falta de moltes dades en alguns camps i considerant com de bo solen ser els RF amb dades tabulars es possible que SVC no doni bons resultats.

En canvi ANN amb múltiple *losses* que maximitzin ambdues mètriques es possible que superi al RF.

Es necessitaria un base de dades molt mes gran, amb més dades variabilitat de dades (donat el fet que son múltiples base de dades fusionats hi ha bastants atributs que no son comuns i només hi ha dades d'una base de dades i no la resta). Hi ha poques aparicions de valors d'alguns paràmetres i poques observacions en general. També més variabilitat de les notes, en les base de dades obtinguts les notes estaven molt juntes en uns valors com la meitat alts i baixos però les zones intermitges no hi tenien cap casi.

També seria molt millor tenir mes paràmetres amb dades més concretes, hi havia moltes de les dades classificades categòricament en "poc", "mitja" i "molt" o similar que podrien aportar més informació amb valors concrets o per exemple paràmetres que podrien estar mes extensos, como dades d'estudi setmanal per àrea no solament general, o notes per àrees i no tan generals, o més concret quines activitats extra curriculars es duen a terme, esports, instruments, escacs, voluntariat, etc.

En resum una base de dades molt més extensiva, completa i amb més paràmetres relacionats amb els estudis i no solament ambient familiar, situació econòmica i estudis generals milloraria molt els resultats, models i recomanador.

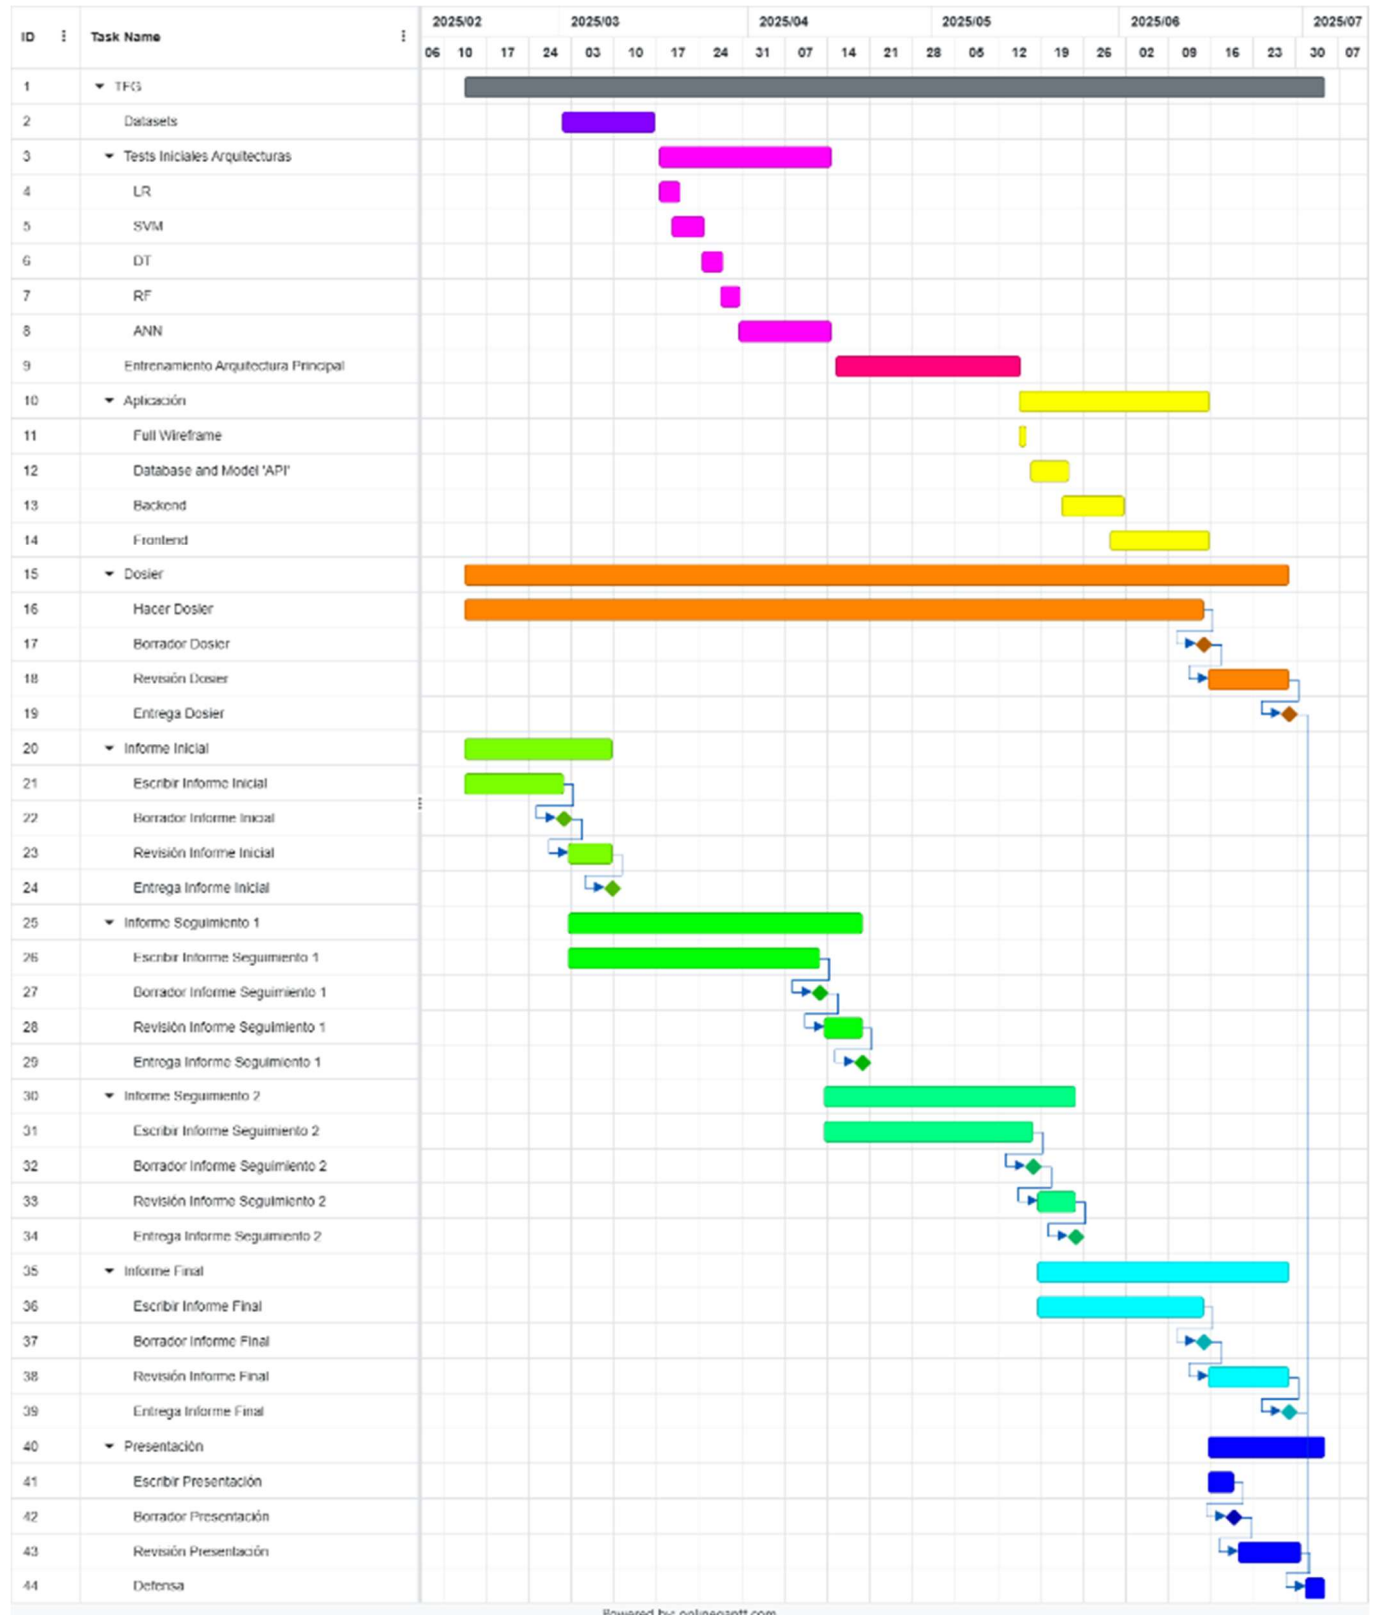
## BIBLIOGRAFIA

- [1] M. V. Martins, D. Tolledo, J. Machado, L. M. T. Baptista, and V. Realinho, "Early Prediction of student's Performance in Higher Education: A Case Study", in Trends and Applications in Information Systems and Technologies, 2021, pp. 166-175. doi: [https://doi.org/10.1007/978-3-030-72657-7\\_16](https://doi.org/10.1007/978-3-030-72657-7_16).
- [2] N. Yilmaz and B. Sekeroglu, "Student Performance Classification Using Artificial Intelligence Techniques", in 10th International Conference on Theory and Application of Soft Computing, Computing with Words and Perceptions - ICSCCW-2019, 2020, pp. 596-603. doi: [https://doi.org/10.1007/978-3-030-35249-3\\_76](https://doi.org/10.1007/978-3-030-35249-3_76).
- [3] C. Romero and S. Ventura, "Educational Data Mining: A Review of the State of the Art", IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), vol. 40, no. 6, pp. 601-618, 2010. doi: <https://doi.org/10.1109/TSMCC.2010.2053532>.
- [4] N. Mduma, K. Kalegele, and D. Machuve, "A Survey of Machine Learning Approaches and Techniques for Student Dropout Prediction", Data Science Journal, Apr. 2019. doi: <https://doi.org/10.5334/dsj-2019-014>.
- [5] A. M. Shahiri, W. Husain, and N. A. Rashid, "A Review on Predicting Student's Performance Using Data Mining Techniques", Procedia Computer Science, vol. 72, pp. 414-422, 2015. doi: <https://doi.org/10.1016/j.procs.2015.12.157>.
- [6] J. L. Rastrollo-Guerrero, J. A. Gómez-Pulido, and A. Durán-Domínguez, "Analyzing and Predicting Students Performance




- by Means of Machine Learning: A Review", *Applied Sciences*, vol. 10, no. 3, 2020. doi: <https://doi.org/10.3390/app10031042>.
- [7] C. Beaulac and J. S. Rosenthal, "Predicting University Students Academic Success and Major Using Random Forests", *Research in Higher Education*, vol. 60, no. 7, pp. 1048–1064, Nov. 2019. doi: <https://doi.org/10.1007/s11162-019-09546-y>.
  - [8] A.-S. Hoffait and M. Schyns, "Early detection of university students with potential difficulties", *Decision Support Systems*, vol. 101, pp. 1–11, Sep. 2017, doi: <https://doi.org/10.1016/j.dss.2017.05.003>.
  - [9] V. Miguéis, A. Freitas, P. J. Garcia, and A. Silva, "Early segmentation of students according to their academic performance: A predictive modelling approach", *Decision Support Systems*, vol. 115, pp. 36–51, Nov. 2018, doi: <https://doi.org/10.1016/j.dss.2018.09.001>.
  - [10] D. Thammasiri, D. Delen, P. Meesad, and N. Kasap, "A critical assessment of imbalanced class distribution problem: The case of predicting freshmen student attrition", *Expert Systems with Applications*, vol. 41, no. 2, pp. 321–330, Feb. 2014, doi: <https://doi.org/10.1016/j.eswa.2013.07.046>.
  - [11] Python Software Foundation. *Python*. (2025). Python Software Foundation. [Online]. Available: <https://www.python.org>
  - [12] Django Software Foundation. *Django*. (2025). Django Software Foundation. [Online]. Available: <https://www.djangoproject.com>
  - [13] Pallets. *Flask*. (2025). Pallets Projects. [Online]. Available: <https://flask.palletsprojects.com>
  - [14] Tiangolo. *FastAPI*. (2025). Tiangolo. [Online]. Available: <https://fastapi.tiangolo.com>
  - [15] Big Sky Software. *HTMX*. (2025). HTMX. [Online]. Available: <https://htmx.org>
  - [16] Mozilla. *JavaScript*. (2025). Mozilla Developer Network. [Online]. Available: <https://developer.mozilla.org/en-US/docs/Web/JavaScript>
  - [17] Caleb Porzio. *AlpineJS*. (2025). AlpineJS. [Online]. Available: <https://alpinejs.dev>
  - [18] Meta Open Source. *React*. (2025). React. [Online]. Available: <https://react.dev>
  - [19] Bootstrap. *Bootstrap*. (2025). Bootstrap. [Online]. Available: <https://getbootstrap.com>
  - [20] Pallets. *Jinja*. (2025). Pallets Projects. [Online]. Available: <https://jinja.palletsprojects.com>
  - [21] World Wide Web Consortium, Web Hypertext Application Technology Working Group. *HTML Standard*. (2025). WHATWG. Available: <https://html.spec.whatwg.org>
  - [22] The PostgreSQL Global Development Group. *PostgreSQL*. (2025). The PostgreSQL Global Development Group. Available: <https://www.postgresql.org>
  - [23] D. Richard Hipp. *SQLite*. (2025). The SQLite Consortium. Available: <https://sqlite.org>
  - [24] V. Realinho, M. Vieira Martins, J. Machado, and L. Baptista, "Predict Students Dropout and Academic Success", *UCI Machine Learning Repository*, 2021. doi: <https://doi.org/10.24432/C5MC89>.
  - [25] N. Yilmaz and B. Şekeroğlu, "Higher Education Students Performance Evaluation", *UCI Machine Learning Repository*, 2019. Available: <https://doi.org/10.24432/C51G82>.
  - [26] P. Cortez. "Student Performance", *UCI Machine Learning Repository*, 2008. [Online]. Available: <https://doi.org/10.24432/C5TG7T>.
  - [27] NumFOCUS, Inc. *Pandas*. (2025). pandas. Available: <https://pandas.pydata.org>
  - [28] Scikit-learn. *Scikit-learn*. (2025). Scikit-learn. Available: <https://scikit-learn.org/stable>
  - [29] Pytorch. The Linux Foundation. (2025). PyTorch. Available: <https://pytorch.org>

## APÈNDIX A: PLANIFICACIÓ



Planificació que es va fer a l'inici del projecte de la repartició de treball.



Progres que realment a seguir el projecte dur a complicacions i similar.